

Speed Dating Tinder



Éric NGUYEN

Data Science & Engineering
DSFS-FT-33





Préambule

Ce projet présente une analyse exploratoire des données (EDA) effectuée sur le célèbre dataset du speed dating de l'Université de Columbia datant de 2004, qui contient des informations sur les préférences, les perceptions, et les matchs entre participants lors d'événements de speed dating. Il a été renommé TINDER. *L'objectif est de faire comme si un site de rencontre avait commandé une étude afin de dégager des insights business.*

Les "insights" Business possibles:

-  Attributs les moins désirables ?
-  Centres d'intérêts communs versus ethnies
-  Perception versus réalité
-  Positions dans la soirée





Analyse descriptive

EDA (Exploratory Data Analysis)

src : skimpy

Data Summary		Data Types		skimpy summary	
Dataset	Values	Column Type	Count		
Number of rows	8378	Float64	174		
Number of columns	195	Int64	13		
		string	8		

		number									
column	NA	NA %	mean	sd	p0	p25	p50	p75	p100	kurt	
id	0	0.000000000000000	281.7	200.0	1	154	281	407	552		
id	1	0.0119368022917104	0.96	1.451	0	0	0	1	1		
gender	1	0.000000000000000	0.5000	0.5	0	0	0	0	1		
hig	0	0.000000000000000	17.15	5.066	0	10	20	30	44		
condn	0	0.000000000000000	1.050	0.197	1	1	1	1	1		
wave	0	0.000000000000000	11.35	5.066	0	10	20	30	44		
round	0	0.000000000000000	10.47	6.358	0	14	20	28	33		
positi	0	0.000000000000000	9.943	5.515	0	0	0	13	22		
positi	1840	22.08108030804747	0.206	1.45	1	1	1	1	1		
order	0	0.000000000000000	0.206	1.45	1	1	1	1	1		
partner	0	0.000000000000000	0.364	1.401	0	0	0	0	1		
aid	0	0.000000000000000	251.5	250.5	0	254	281	408	552		
match	195	1.000000000000000	0.1047	0.288	0	0	0	0	0		
int_corr	0	0.000000000000000	0.106	0.332	-0.85	0	0	0	0		
sawerac	0	0.000000000000000	0.3958	0.4891	0	0	0	0	1		
rac_o	148	1.741363333333333	29.30	1.504	0	0	0	0	0		
rac_o	73	0.071320872051072	2.757	1.221	0	0	0	0	0		
pr_o_11	80	0.000000000000000	12.5	1.57	0	0	0	0	0		
pr_o_10	80	1.000000000000000	17.4	7.444	0	10	20	30	44		
pr_o_10	80	1.000000000000000	20.27	7.702	0	10	20	30	44		
pr_o_10	80	1.000000000000000	17.46	6.888	0	10	20	30	44		
pr_o_10	115	1.37134402210658	10.40	1.522	0	10	20	30	44		
pr_o_10	115	1.37134402210658	11.00	0.303	0	10	18.04	15	25		

- Dataset de 195 colonnes et 8378 lignes
- Nombre colonnes avec des valeurs manquantes : 182 soit 93%
- Valeurs manquantes dans tout le dataset : 26%
- identifiants et données démographiques :
15 colonnes | Âge, genre, race, domaine d'études, profession envisagée
- Critères d'attraction : 5 à 6 colonnes selon les cas |
attractivité, sincérité, intelligence, sens de l'humour, ambition, intérêts communs.
- Match et décision : 7 colonnes
- Préférences personnelles : 17 colonnes

Float64 : 174 colonnes
Int64 : 13 colonnes
String : 8 colonnes






Souhait de carrière

EDA (Exploratory Data Analysis)

Carrière souhaitée selon le Sexe




On observe encore une bonne dichotomie de carrière entre Homme et Femme. Est-ce que l'ambition sera-t-elle un critère important ?



Âge et rencontre (EDA)

Distribution de l'âge selon le sexe



C'est une population jeune (entre 20 et 35) avec quelques outliers mais on observe tout de même que le nombre de "match" **diminue** sensiblement avec l'âge.

Taux de match par âge




Taux de match par âge et par sexe (jusqu'à 42 ans)






Ethnies et rencontre (EDA)

Répartition des ethnies parmi les participants



Ici sous représentation de la population "noire" (6.03%).
De base, homme et femme souhaitent rencontrer une personne de la même ethnie. En termes de proportion d'individus dans la distribution : European > Asian > Latino > Black > Other.


L'importance de l'Ethnie dans le choix du Partenaire





Ethnies et rencontre (EDA)

Répartition des matchs mutuels : même ethnie vs différente ethnie chez la Femme




Femme



On observe que malgré une volonté de rencontrer une personne de la même ethnie, dans les faits, on change rapidement d'avis. Plus de **60% des hommes et des femmes** ont "matché" avec des ethnies différentes.

Répartition des matchs mutuels : même ethnie vs différente ethnie chez l'homme




Homme





Je me note, les autres me notent

Ce que je pense de moi vs Ce que les autres pensent de moi




On se surestime légèrement. Mais finalement, l'image qu'on a de soi est assez conforme à l'image que les autres ont de nous.





Les critères de sélection (EDA)

Critères d'attraction: **ce que l'on recherche** 🔍 chez l'autre




Ce type de représentation en BoxPlot est intéressant pour révéler les "outliers" (valeurs extrêmes) et ici, beaucoup de valeurs extrêmes pour l'attractivité. Mais est-ce que ce critère sera-t-il déterminant pour le "matching" ?



Les critères de sélection (EDA)

Les critères souhaités avant le Dating




Les **hommes** préfèrent l'**attractivité** (le physique) tandis que les **femmes** privilégient l'**intelligence** dans leur intention de rencontre. L'ambition (carrière) ou les centres d'intérêts viennent en dernier.



Les critères de sélection (EDA)


Les critères après la volonté de Matcher des deux côtés



La distribution des points s'équilibre une fois que la personne plait et que l'on souhaite "matcher". L'intelligence et la sincérité l'emportent sur le reste mais c'est dans un mouchoir de poche.




Matching (EDA)



Les matches sont très faibles sur la totalité.
Gouffre énorme entre le **match estimé** et le **match réel**.
Les hommes semblent beaucoup plus confiants dans leurs capacités à matcher.


Comparaison : Match Réel vs Match Estimé (Ventilation par genre)






Représentation Radar (EDA)

Les critères recherchés avant le dating



L'Utilisateur souhaite revoir la personne et juge ses critères




La représentation en radar permet une meilleure distinction visuelle des écarts. **Face à la personne, les critères changent** par rapport à ses souhaits.



Contact après match

Comparaison : nombre moyen de matchs **contactés** vs **reçus** selon le genre




Comme on le constate, les hommes sont beaucoup plus **entreprenants que les femmes** et reçoivent **moins de contacts**.



Position dans la soirée

Ordre de passage vs Matching



Plus on passe tard, moins on fait de "matches"

Merci pour
votre attention.

