



Jedha

Conversion Rate Challenge

Data Science Weekly

A free weekly newsletter of Data Science articles, news, tools, libraries, and cool projects

Enter your email below to receive the newsletter every Thursday

Subscribe

By subscribing you agree to [Substack's Terms of Use](#), our [Privacy Policy](#) and our [information collection notice](#)

#substack

One email every Thursday.

Easy to unsubscribe.

No spam — we keep your email safe and do not share it.

Check out our [data science newsletter archive](#) for sample issues.

Eric NGUYEN

Data Science & Engineering
DSFS-FT-33



Brief Marketing

Ce projet s'inspire des compétitions de machine learning organisées sur des plateformes comme [Kaggle](https://www.kaggle.com/). L'objectif est de concevoir un modèle prédictif capable de déterminer si un visiteur du site www.datascienceweekly.org va s'abonner à la newsletter hebdomadaire.

Les livrables



EDA



Machine Learning Supervisé



Grid Search et Regulations



EDA

skippy summary

Data Summary		Data Types	
Dataframe	Values	Column Type	Count
Number of rows	284580	int64	4
Number of columns	6	string	2

number

column	NA	NA %	mean	sd	p0	p25	p50	p75	p100	hist
age	0	0	30.56	8.267	17	24	30	36	123	
new_user	0	0	0.6855	0.4643	0	0	1	1	1	
total_pages_visited	0	0	4.873	3.342	1	2	4	7	29	
converted	0	0	0.03226	0.1767	0	0	0	0	1	

string


column	NA	NA %	shortest	longest	min	max	chars per row	words per row	total words
country	0	0	UK	Germany	China	US	2.93	1	284580
source	0	0	Ads	Direct	Ads	Seo	3.69	1	284580

End

Pas de valeurs manquantes

Outliers


Ratio Convertis vs non convertis





Matrice de corrélation



Correlation Matrix



À ce stade, seule la feature **total_pages_visited** semble avoir une corrélation importante avec **converted**



EDA : Distribution pays et conversions




La chine est le **2e visiteur** mais c'est le pays qui convertit le moins en termes de ratio.
Notons une forte conversion chez les Allemands.



EDA : pages views vs conversions


Comparaison des moyennes des pages visitées et âge par statut de conversion




Ce graphique permet de confirmer que le nombre de pages vues est important ainsi que l'âge et cela se vérifie aussi sur la population chinoise




EDA : autres features et conversions




new_user



âge




source



Pages_visited




EDA : outliers




Ratio outliers âge
: **0.36%**

(3*std)



Ratio outliers
pages_visited :
1.80%

(3*std)



Challenge Rate Leaderboard

	modele	f1	precision	recall	rank
0	Sonia-model4-Ensemble-LogReg-XGBoost	0.765471	0.815061	0.721569	1
1	SeverineLeguy-LogReg2	0.764982	0.816463	0.719608	2
2	ronalyn-logreg-v3	0.764431	0.813953	0.720588	3
3	Sonia-model3-LogReg-optimal	0.763280	0.805223	0.725490	4
4	elmehdi-ellaoui-lr-v2	0.762346	0.801948	0.726471	5
5	ronalyn-logreg-v2	0.762249	0.804135	0.724510	6
6	elmehdi-ellaoui-lr-v4	0.760549	0.823059	0.706863	7
7	michelb-Rf-XGB-prob	0.760357	0.817362	0.710784	8
8	michelb-Rf-XGB-prob-v2	0.759788	0.825287	0.703922	9
9	elmehdi-ellaoui-lr-v5	0.758985	0.823394	0.703922	10
10	Sev-stacking	0.758842	0.836879	0.694118	11
11	Zacharie-XGBoost	0.758770	0.843938	0.689216	12
12	Sonia-model2-XGBoost	0.758584	0.837678	0.693137	13
13	Loic-Astral5	0.758184	0.821510	0.703922	14
14	elmehdi-ellaoui-v-clf	0.758073	0.768379	0.748039	15
15	youenn-patat-gbc	0.757543	0.840909	0.689216	16
16	Loic-Astral4	0.757333	0.830409	0.696078	17
17	Eric-Nguyen-DS33-V3	0.756959	0.833726	0.693137	18
18	Loic-Astral1	0.756844	0.836299	0.691176	19
19	Sev-voting	0.756728	0.838902	0.689216	20
20	Loic-Gravity	0.756728	0.838902	0.689216	21
21	Loic-Astral2	0.756356	0.822581	0.700000	22
22	Eric-NGUYEN-XG-FIN	0.756348	0.842359	0.686275	23
23	youenn-patat-voting	0.755940	0.841346	0.686275	24
24	jej-stxgbt-FE	0.755461	0.827305	0.695098	25
25	michelb-Rf-XGB	0.755411	0.842995	0.684314	26
26	jej-stxgbt	0.755342	0.829812	0.693137	27
27	Hector-LR	0.755146	0.843826	0.683333	28
28	youenn-patat-mlpclassifier	0.755146	0.843826	0.683333	29
29	youenn-patat-logistic-reg-2	0.755146	0.843826	0.683333	30

0,76... semble être la plus haute marche du podium.
Classement 18e avec XGboost

Prenons donc comme métriques de référence :

F1 : 0.765471

Precision : 0.815061

Recall : 0.721569




Premier modèle

Régression Logistique V1

Métriques globales :

	precision	recall	f1-score	support
0	0.99	1.00	0.99	275400
1	0.86	0.69	0.76	9180
accuracy			0.99	284580
macro avg	0.92	0.84	0.88	284580
weighted avg	0.99	0.99	0.99	284580

✓ bien prédit



✗ faux positifs

✗ faux négatif

✓ bien prédit

Métriques de référence :

F1 : 0.765471
Precision : 0.815061
Recall : 0.721569

Logistic V1 Score

F1 : 0.7572
Precision : 0.8551
Recall : 0.6795



Modèles : comparaison score

Modèle	Précision	Recall	F1-Score
Etalon	0.815061	0.721569	0.765471
Logistic Regression	0.8551	0.6795	0.7572
Random Forest	0.8206	0.6703	0.7379
XGBoost	0.8466	0.6832	0.7562
XGBoost Optuna	0.8532	0.6849	0.7598

$$\text{Precision} = \frac{\text{Vrais Positifs}}{\text{Vrais Positifs} + \text{Faux Positifs}}$$

$$\text{Recall} = \frac{\text{Vrais Positifs}}{\text{Vrais Positifs} + \text{Faux Négatifs}}$$

$$\text{F1 Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Precision : parmi les éléments prédits comme positifs, quelle proportion est correcte (*faux positifs inclus*).

Recall (Rappel) : parmi tous les éléments positifs, quelle proportion est retrouvée.

F1 Score : moyenne harmonique de la précision et du rappel → équilibre entre fiabilité et couverture.



Modèles : gestions des Outliers

Modèle	Précision	Recall	F1-Score
Etalon	0.815061	0.721569	0.765471
Logistic Regression	0.7733	0.5533	0.6450
Random Forest	0.8338	0.6133	0.7067
XGBoost	0.7635	0.5541	0.6421
XGBoost Optuna	0.7598	0.5752	0.6548



Modèles : over/under Sampling


Modèle	Précision	Recall	F1-Score
Etalon - Score à battre	0.815061	0.721569	0.765471
Logistic Regression	0.8081	0.7259	0.7648
Random Forest	0.8015	0.6941	0.7439
XGBoost	0.8035	0.7227	0.7610
XGBoost Optuna	0.8063	0.7292	0.7658

Light GBM		0.8185	0.7238	0.7682
-----------	---	---------------	---------------	---------------



Features importants

📊 Importance des Features (Gain - XGBoost)





Conclusion et recommandations

Optimiser le nombre de pages vues est la clef pour obtenir plus de souscriptions
ce qui veut dire :



- Écrire un contenu de qualité (boost pages vues),
- Optimiser la **navigation** (boost pages vues)
- Créer une nouvelle **charte graphique plus attractive** (changer les couleurs)
- Call to action plus clair
- **L'âge** est clairement un levier ce qu'il faut creuser davantage et travailler sur le contenu adapté
- La **Chine est la 2e audience** mais très peu de conversions
 - est-ce du spam ?
 - problème de langue ?



Attention : La source Ads a disparu des features importantes, ce qui veut dire que le modèle privilégie le SEO ou Direct. Il faudrait tagger correctement le parcours clients pour que le modèle puisse distinguer les deux (construire un modèle d'attribution).

Data
Science
Weekly

Merci de
votre attention



Annexes

Data Science Weekly

A free weekly newsletter of Data Science articles, news, tools, libraries, and cool projects

Enter your email below to receive the newsletter every Thursday

Type your email... [Subscribe](#)

By subscribing you agree to [Substack's Terms of Use](#), our [Privacy Policy](#) and our [Information collection notice](#)

One email every Thursday.

Easy to unsubscribe.

No spam — we keep your email safe and do not share it.

Check out our [data science newsletter archive](#) for sample issues.

Faute de frappe
difficilement
excusable pour le
peu de contenu

Message reçu après
l'inscription. Il n'y a
pas de lien de
réponse pour le
premier question. ?

Welcome to **Data Science Weekly** Newsletter [Inbox x](#)

Data Science Weekly Newsletter <datascienceweekly@substack.com> [Unsubscribe](#)
to me ▾

Tue, Aug 5, 10:12AM ☆



Hi, quick question: What are you hoping to get from the "**Data Science Weekly**" newsletter?

Thanks!
Sebastian

© 2025 [datascienceweekly.org](#), a service of DATAYOU, LLC
548 Market Street PMB 72296, San Francisco, CA 94104
[Unsubscribe](#)

[Get the app](#)

[Start writing](#)