



eCommerce

Never stop exploring.

Éric NGUYEN

Data Science & Engineering
DSFS-FT-33



Brief Marketing

Le département marketing de The North Face souhaite exploiter les méthodes unsupervised learning pour améliorer l'UX et augmenter les taux de conversion sur son site e-commerce. Deux axes principaux ont été identifiés :

Système de recommandation : Proposer aux utilisateurs des produits similaires "Vous pourriez aussi aimer..."

Réorganisation du catalogue : Topic modeling pour remettre en question les catégories existantes et améliorer la navigation sur le site.

Les livrables




Un modèle de clustering (DBSCAN)


Des nuages de mots par cluster pour analyser les groupes.

Un système de recommandation fonctionnel utilisable en interaction.

Un modèle de modélisation de thèmes (TruncatedSVD) entraîné.

Des nuages de mots par thème latent pour interpréter les sujets découverts.





DBSCAN - étape 1

1er Nettoyage



```
x.replace("<i>","")\
.replace("</i>","")\
.replace("<br>","")\
.replace("<br>","")\
.replace("<b>","")\
.replace("</b>","")\
.replace("<ul>","")\
.replace("</ul>","")\
```

Lemmatization
Stop Words
Join



2e Nettoyage


```
.replace(" .", " ")
.replace(" .", " ")
.replace("'", " ")
.replace("'", " ")
.replace(" .", " ")
.replace(" %", "%")
.replace(" g", "g")
.replace(" oz", "oz")
.replace("-oz", "oz")
.replace(" (", " ")
.replace(")", " ")
```

T F I D F

v.vocabulary_

```
{'active': 386,
'classic': 944,
'boxer': 745,
'reason': 2955,
'cult': 1179,
'favorite': 1571,
'cool': 1094,
'especially': 1494,
'sticky': 3542,
'situation': 3351,
'quick': 2910,
'dry': 1376,
'lightweight': 2192,
'underwear': 3982,
'minimal': 2387,
'space': 3462,
'travel': 3894,
'pack': 2635,
```

TF-IDF = Term Frequency – Inverse Document Frequency



DBSCAN - Clustering

Pourcentage de Bruits : 16.8% esp : 0.6 min_samples : 2 Nombres de Clusters : 79
Pourcentage de Bruits : 30.4% esp : 0.6 min_samples : 3 Nombres de Clusters : 45
Pourcentage de Bruits : 37.6% esp : 0.6 min_samples : 4 Nombres de Clusters : 35
Pourcentage de Bruits : 46.4% esp : 0.6 min_samples : 5 Nombres de Clusters : 25
Pourcentage de Bruits : 58.8% esp : 0.6 min_samples : 6 Nombres de Clusters : 15
Pourcentage de Bruits : 62.0% esp : 0.6 min_samples : 7 Nombres de Clusters : 13
Pourcentage de Bruits : 63.4% esp : 0.6 min_samples : 8 Nombres de Clusters : 12
Pourcentage de Bruits : 70.6% esp : 0.6 min_samples : 9 Nombres de Clusters : 8
Pourcentage de Bruits : 74.4% esp : 0.6 min_samples : 10 Nombres de Clusters : 6
Pourcentage de Bruits : 4.6% esp : 0.7 min_samples : 2 Nombres de Clusters : 26
Pourcentage de Bruits : 7.4% esp : 0.7 min_samples : 3 Nombres de Clusters : 19
Pourcentage de Bruits : 10.8% esp : 0.7 min_samples : 4 Nombres de Clusters : 18
Pourcentage de Bruits : 16.6% esp : 0.7 min_samples : 5 Nombres de Clusters : 12
Pourcentage de Bruits : 19.8% esp : 0.7 min_samples : 6 Nombres de Clusters : 11
Pourcentage de Bruits : 22.2% esp : 0.7 min_samples : 7 Nombres de Clusters : 13

Recherche des meilleurs paramètres pour trouver un nombre de clusters idéaux, et un pourcentage d'outliers le plus bas possible. Ici **4,6% d'outliers pour 26 clusters.**

Nous pourrions aussi choisir **7,4% pour 19 clusters**


eps : distance maximale entre deux échantillons

min_samples : nombre minimum d'échantillons

metric="cosine" : similarité cosinus capture la similarité sémantiques entre les documents, elle est bien adaptée aux vecteurs de grande dimension.


[illegible]

Words Cloud du cluster 15




Sparse Matrix to Dense Matrix

Top 20 des mots les plus significatifs (TF-IDF max)




Un classement par scores TF-IDF élevés permet d'identifier des mots potentiellement rares dans le corpus, mais fortement discriminants. Ces mots, souvent techniques ou spécifiques à un type de produit, sont essentiels (**ou pas**) pour distinguer finement les **groupes de produits** dans un système de clustering ou de **recommandation**.



Score TF-IDF et Fréquences

Comparaison : mots marquants vs mots fréquents



Mots importants mais rares versus des mots fréquents mais génériques.

[illegible]

repellent shoelace beach south 20z neck temper close crowning Gentire adjustable rear dark underbill heat reduces glare fabric build fast coolmax headband decidedly wick moisture deflect shadow web elastic snug noodle logo made china welcome landscape black sun center breathability rear buckle 60z light 100g fit cotton nylon oz weight headband wick al fortuitous tonal run moisture dark reduces glare billi soft tropical glare face panel dry canvas day shield polyester protection shed open mountain low effect stay ventilation cut glare profile sand cover reduce glare wispy polyester weight complete customize ear forgo supply hand Cap staying swing fabric pound dente

Words Cloud du cluster 15



Recommandation de produits

57

Choisissez un ID entre 0 et 499 : (Appuyez sur 'Entrée' pour confirmer ou sur 'Échap' pour annuler)

Le label pour l'ID 57 est 0.

Voici 5 article(s) similaire(s) à l'ID 57 :

	id	description
441	442	Cap 3 bottoms - Ice climbers and alpinists kno...
486	487	Cap 1 crew - When it comes to moisture, this l...
0	1	Active classic boxers - There's a reason why o...
380	381	R2 jkt - A modern mountain staple, the adaptab...
19	20	Cap 1 graphic t-shirt - This tee is made from ...





Moteur de recommandation - python





Topic Modeling : Truncated SVD



	topic_1	topic_2	topic_3	topic_4	topic_5	topic_6	topic_7	topic_8	topic_9	topic_10	topic_11	topic_12	topic_13	topic_14	topic_15	topic_16	topic_17	topic_18	topic_19	text
0	0.269334	-0.052115	0.188441	0.077587	-0.126032	-0.000442	-0.039954	-0.027882	-0.155181	-0.030506	0.017291	-0.054144	-0.031007	0.033757	0.025625	-0.019270	-0.057624	0.037730	0.040729	active classic boxer reason boxer cult favorit...
1	0.268035	-0.069178	0.101221	0.092805	-0.020273	0.084194	-0.048604	-0.019362	-0.109487	0.046076	-0.005426	-0.182320	-0.002791	0.068705	-0.058000	0.036133	0.065490	0.104760	0.061806	active sport boxer brief skin upglory require ...
2	0.255211	-0.092521	0.102548	0.025111	-0.027444	0.089129	-0.002769	0.051107	-0.038312	0.019748	-0.009102	-0.212177	0.041086	0.081288	-0.054459	0.001489	0.068489	0.068094	0.074061	active sport brief superbreathable fly brief m...
3	0.374912	-0.246397	-0.115618	-0.126347	0.046167	-0.019475	-0.003801	-0.038846	-0.082528	0.123741	0.006984	-0.062384	-0.162403	-0.045120	0.046300	0.022221	-0.018976	-0.045034	0.201947	alpineguide pant skin climb ice switch rock tr...
4	0.399452	-0.264755	-0.036292	-0.228289	-0.028985	-0.053859	0.035456	0.079081	-0.034346	0.193807	0.032349	0.020787	-0.217370	0.278639	0.051683	-0.052400	-0.028064	-0.015241	-0.006837	alpine wind jkt high ridge steep ice alpine ja...
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
495	0.312408	-0.070397	0.390471	0.045966	-0.252298	-0.036696	0.013884	-0.072402	-0.330971	-0.108896	0.005834	-0.024679	-0.055755	0.005225	-0.028847	0.006817	-0.064166	-0.043835	0.053446	cap 2 bottom cut loose madden crowd search und...
496	0.359614	-0.072957	0.481281	-0.027145	-0.308001	-0.059878	0.034296	0.008712	-0.259510	-0.173150	-0.011042	0.062510	-0.114888	0.077777	-0.073622	0.107344	-0.019367	0.000730	-0.020137	cap 2 crew take edge fickle weather clear...
497	0.337991	-0.207848	-0.066699	-0.231694	-0.012386	-0.142335	0.159014	-0.118710	0.050841	0.004322	0.027331	0.110905	0.082365	-0.029647	-0.016876	-0.017824	-0.034444	0.002523	0.016401	time shell need use morning time umbrella time...

	topic_1	topic_2	topic_3	topic_4	topic_5	topic_6	topic_7	topic_8	topic_9	topic_10	topic_11	topic_12	topic_13	topic_14	topic_15	topic_16	topic_17	topic_18	topic_19
000	0.002749	0.000156	-0.001578	-0.004359	0.002321	0.002035	0.000962	0.003721	-0.002214	0.004728	0.001014	-0.000964	-0.000445	0.008661	-0.007274	-0.004420	0.000284	-0.003301	0.015847
03oz	0.000595	-0.000742	-0.000728	-0.001395	0.000391	-0.000985	0.001346	-0.001874	0.000865	-0.001791	-0.000204	0.001523	0.001225	-0.001150	-0.000913	-0.000592	0.000090	-0.000333	-0.000973
0g	0.005948	0.003930	-0.005103	0.011962	-0.001287	-0.012887	0.002694	0.005706	0.003260	-0.013028	0.002290	0.011343	0.003495	0.015759	0.008402	0.010360	-0.018865	0.030991	0.025809
0oz	0.005948	0.003930	-0.005103	0.011962	-0.001287	-0.012887	0.002694	0.005706	0.003260	-0.013028	0.002290	0.011343	0.003495	0.015759	0.008402	0.010360	-0.018865	0.030991	0.025809
10	0.049759	-0.005762	-0.042008	0.089171	0.011454	-0.045789	0.023881	0.004780	0.004057	-0.028117	0.009441	0.000506	0.013463	0.034002	0.017382	0.040796	-0.033800	0.059688	0.075018
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
zippergussete	0.003485	-0.004191	-0.003315	-0.002809	0.002125	-0.000728	-0.001142	-0.002743	-0.005926	0.009159	0.000576	-0.004627	-0.012485	-0.002929	0.004937	0.001052	-0.001208	-0.003833	0.015746
zippergusseted	0.000689	-0.000986	-0.000970	-0.000626	0.000599	0.000291	0.000352	-0.000441	-0.001046	0.000683	0.000164	-0.000541	-0.000258	0.000738	0.000510	0.000185	0.000057	-0.000967	0.002805
zippersfabric	0.000868	-0.001262	-0.000924	-0.002120	0.000497	0.000286	-0.003294	0.006756	-0.000352	-0.003138	-0.000891	0.000125	-0.001039	-0.000750	0.001122	0.000076	0.000860	0.001605	0.001433
zips	0.014527	-0.019771	-0.015235	-0.028451	0.005174	-0.011790	0.026945	-0.048689	0.016223	-0.022854	-0.001715	0.029598	0.001394	-0.028760	-0.057234	-0.002892	0.019014	0.019798	-0.013193
zone	0.007809	-0.011464	-0.002631	-0.017714	0.018474	0.003601	0.016881	-0.026790	0.012181	-0.060689	-0.013500	-0.079931	0.059790	0.056479	0.044269	0.010835	-0.042734	-0.043048	-0.004531

LSA via TruncatedSVD, appliqué à la matrice TF-IDF des descriptions produits = **19 dimensions**
 Ensuite extraction des mots les plus influents et identification de son topic dominant.



Poids Max global dans un nuage de mots




Sélection de 20 mots les plus significatifs

L'ensemble mots dominants de façon globale



Sélection top 20 par topic (topic_1)

Top 20 des mots les plus significatifs - topic_1




Pour les prochains études, toutes les données techniques devraient être nettoyées à moins qu'elles aient une importance majeur.

Dans ce topic un nous pouvons retenir : **recycle, recyclable, durable**



Sélection top 20 par topic (topic_9)

Top 20 des mots les plus significatifs - topic_16



Le topic modeling donne des résultats différents qui pourraient être utile pour utiliser une navigation : **transverse** **tender** / **compressibility** par exemple

Merci de
votre attention