

Walmart Sales



Éric NGUYEN

Data Science & Engineering
DSFS-FT-33



Brief Marketing

Le service marketing de Walmart souhaite disposer d'un modèle de machine learning capable d'estimer avec précision les **ventes hebdomadaires** dans ses magasins. Ce modèle permettra de mieux comprendre l'impact des indicateurs économiques sur les ventes et d'optimiser la planification des futures campagnes marketing.

Les livrables



EDA



Machine Learning Supervisé



Grid Search et Regulation



EDA

Analyse descriptive rapide avec Skimpy

Ecartype élevé
pour les ventes
Weekly_Sale
(268 900 et 2
771 000)

Petit Dataset
avec valeurs
manquantes
conséquentes

skimpy summary

Data Summary

Dataframe	Values
Number of rows	150
Number of columns	8

Data Types

Column Type	Count
float64	7
string	1

number

column	NA	NA %	mean	sd	p0	p25	p50	p75	p100	hist
Store	0	0	9.867	6.231	1	4	9	15.75	20	
Weekly_Sales	14	9.333333333333333	1250000	647500	268900	605100	1261000	1806000	2771000	
Holiday_Flag	12	8	0.07971	0.2718	0	0	0	0	1	
Temperature	18	12	61.4	18.38	18.79	45.59	62.98	76.34	91.65	
Fuel_Price	14	9.333333333333333	3.321	0.4781	2.514	2.852	3.451	3.706	4.193	
CPI	12	8	179.9	40.27	126.1	132	197.9	214.9	227	
Unemployment	15	10	7.598	1.577	5.143	6.598	7.47	8.15	14.31	

string

column	NA	NA %	shortest	longest	min	max	chars per row	words per row	total words
Date	18	12	18-02-2011	18-02-2011	01-06-2012	31-12-2010	10	0.88	132


End

p0, p25, p50,
p75, p100 :
Percentiles



Analyse descriptive

- **Store** : La variable, discrète correspond aux magasins Walmart.
- **Weekly_Sales** : Les ventes hebdomadaires suivent une distribution asymétrique avec une longue queue à droite, indiquant que certaines semaines ont des ventes très élevées par rapport à la majorité.
- **Holiday_Flag** : Cette variable binaire (0 ou 1), indiquant si une semaine correspond à une période de vacances ou non.
- **Temperature** : distribution normale, avec une moyenne autour de 60°F et une dispersion modérée.
- **Fuel_Price** : Le prix du carburant suit également une distribution normale, avec une moyenne proche de 3.5 \$/gallon.
- **CPI** : L'indice des prix à la consommation semble relativement stable, avec une distribution centrée autour de 220.
- **Unemployment** : Le taux de chômage montre une distribution légèrement asymétrique, avec une concentration autour de 7%.
- **Date** : variable temporelle pourrait indiquer un effet saisonniers




Target




EDA

Pairplot





Matrice de Corrélation





EDA : Pairplot & Matrice de corrélation


- **Store** : Aucune corrélation claire avec le numéro du magasin
- **Holiday_Flag** : Une augmentation significative des ventes lorsqu'il y a des vacances (**Holiday_Flag = 1**).
- **Temperature** : Une relation positive faible mais visible entre la température et les ventes. Les ventes augmentent légèrement lorsque la température augmente.
- **Fuel_Price** : Une corrélation négative faible entre le prix du carburant et les ventes. Les ventes tendent à diminuer légèrement lorsque le prix du carburant augmente.
- **CPI** : Une corrélation positive faible entre le CPI et les ventes. Les ventes augmentent légèrement lorsque le CPI augmente.
- **Unemployment** : Une corrélation négative faible entre le taux de chômage et les ventes. Les ventes tendent à diminuer lorsque le taux de chômage augmente.
- **Store** : Corrélation faible (**0.12**). Faible à pas de corrélation visible.
- **Holiday_Flag** : Corrélation très faible (**0.04**).
- **Temperature** : Corrélation légèrement négative (**-0.17**). Une baisse modérée des ventes semble liée aux températures plus élevées, mais cette relation est faible.
- **Fuel_Price** : Corrélation légèrement positive (**0.06**). Les prix du carburant semblent avoir une influence minime sur les ventes.
- **CPI** : Corrélation négative modérée (**-0.29**). Une hausse du CPI Semble légèrement négativement corrélé avec les ventes, mais la relation est faible."
- **Unemployment** : Corrélation légèrement positive (**0.06**). Le taux de chômage semble avoir une influence minimale sur les ventes.





Focus Weekly_Sales & Holidays_Flag

Distribution des Ventes Hebdomadaires selon la Présence d'un Jour Férié




Jours fériés, ventes légèrement plus élevées (prix panier) que les **jours normaux**. (vente moyenne plus élevée, médiane plus élevée)



Chômage vs Ventes

Ventes vs Taux de chômage par magasin - Couleur par magasin



Il est difficile de dire si le taux de chômage a une répercussion sur les ventes. Note (le store 12, outlier, réalise quand même des ventes avec taux de chômage de **13,89%**)




CPI vs Ventes



On retrouve notre store 12, qui est dans la zone CPI la plus basse en lien conforme à son taux de chômage.
Là encore, on peut pas dire que le CPI influence les ventes.

Ventes hebdomadaires vs CPI par magasin - Couleur par magasin





Nettoyage BDD

Avant

column	NA	NA %
Store	0	0
Weekly_Sales	14	9.333333333333334
Holiday_Flag	12	8
Temperature	18	12
Fuel_Price	14	9.333333333333334
CPI	12	8
Unemployment	15	10

Après

column	NA	NA %
Store	0	0
Weekly_Sales	0	0
Holiday_Flag	0	0
Temperature	0	0
Fuel_Price	0	0
CPI	0	0
Unemployment	0	0
Year	10	11.111111111111111
Month	10	11.111111111111111
Day	10	11.111111111111111

Suppression de tous les outliers qui rentrent pas dans les **3 Standard deviations** : **Temperature**, **Fuel_Price**, **CPI**, **Unemployment** soit 99,7% des données se trouve dans les 3 écarts types de part et d'autres de la moyenne.

Il reste des "nan" dans le **Holiday_Flag**, on remplace par **0** (jour non férié, cas le plus probable).

La variable **Date** est splittée en Year, Month et Day qui subiront l'**K-Nearest Neighbors Imputer** (*k observations les plus similaires* (voisins))



Linear Regression

R2 score on training set : **0.9868**

R2 score on test set : **0.9363**

The cross-validated R2-score is : **0.2869**

The standard deviation is : **0.8421**

Combattre l'overfitting : le modèle capture sûrement du bruit et ne parvient pas à généraliser au test. Il y a probablement un moyen d'optimiser

Le modèle s'ajuste bien aux données, la target prédite par les variables indépendantes

Le modèle se généralise bien malgré un problème léger d'overfitting

Score de validation bas, performance variable, instable

Écart type élevé, performance variable (différent plis de validation)

R2 score : proportion de variance de la target expliqué par le modèle

Cross-validated R2-score : R^2 calculé en utilisant la validation croisée (par exemple, k-fold)

The standard deviation : dispersion des valeurs prédites (ou réelles) de la target autour de leur moyenne



Regulation RIDGE

RIDGE / R2 score on training set : **0.9861**

Le modèle s'ajuste bien aux données,
la target prédite par les variables
indépendantes

RIDGE / R2 score on test set : **0.9399**

Le modèle se généralise bien malgré
un problème léger d'overfitting

The cross-validated R2-score is : **0.7000**

Score de validation en hausse, le
modèle est plus stable

The standard deviation is : **0.1320**

Écart type faible, score de validation
croisée stable



Regulation LASSO

LASSO / R2 score on training set : **0.9867**

LASSO / R2 score on test set : **0.9379**

The cross-validated R2-score is : **0.3117**

The standard deviation is : **0.8080**

Le modèle s'ajuste bien aux données,
la target prédite par les variables
indépendantes

Le modèle se généralise bien malgré
un problème léger d'overfitting

Score de validation décevante,
performance variable



Écart type élevé, performance
variable (différents folders de
validation)

Ridge Vs Lasso : à ce stade Ridge semble plus robuste à cause
de la Standard deviation qui est plutôt bas.



Features importants

Comparaison Ridge vs Lasso : Importance des features



Mis à part quelques différences mineures, il n'est pas possible pour le moment de partager entre Ridge et Lasso. En revanche, on sait déjà que les "Stores" (la stratégie autour de ces stores) sont importants pour les ventes.



Optimisation

KNNImputer : 20
CV : 5

RIDGE

Best hyperparameters : `{'alpha': 0.001}`

RIDGE / R2 score on training set : **0.9816**

RIDGE / R2 score on test set : **0.9484**

Cross_Val_Score MEAN sur le train set : **0.9497**

Cross_Val_Score Std sur le train set : **0.0267**

Suppression de **Day**, et **Holiday_Flag** (qui semblent important mais reste en de-ça, des tendances mensuelles ainsi que du lieux (store)

LASSO

Best hyperparameters : `{'alpha': 10}`

LASSO / R2 score on training set : **0.9817**

LASSO / R2 score on test set : **0.9483**

Cross_Val_Score MEAN sur le train set : **0.9488**



Cross_Val_Score Std sur le train set : **0.0277**

Ridge Vs Lasso : Ridge qui était déjà robuste se montre un peu plus performant, son R2 sur le test set est de **0,9484** versus **0,9483** de Lasso. Mais les deux peuvent être utilisés. Préférence à Ridge qui ne réduit pas à zéro certaines features.



Résultat

Comparaison des features les plus importantes : Ridge vs Lasso



Les 2 régulations convergent.
Mis à part de très légères
différences à peu perceptibles.



Merci de
votre attention