



Driving the future of shared mobility



Éric NGUYEN

Data Science & Engineering
DSFS-FT-33



Brief Marketing

GETAROUND est un site de location de véhicules entre particuliers.

L'objectif est d'aider l'équipe produit à prendre

- implémentation d'un **délai minimum entre deux locations** afin de réduire les retards, tout en minimisant l'impact sur les revenus.
- **API de prédiction de prix** basée sur un modèle de Machine Learning.


Les livrables



EDA



Une calculatrice de seuil de perte de revenue à cause du retard en 2 locations




Une Machine Learning pour prédire un prix de location journalier via une API




EDA

Grandes dispersions
dans la restitution du
véhicules



Valeurs manquantes
très importantes

Données manquantes en pourcentage







EDA

State of the Car

- ended
- canceled



15,3% de personnes annulent leurs locations.




En mobile, plus de "canceled"



EDA - Focus "Cancel"


Groupe Cancel : Checkin Type



Probablement plus de facilité de "canceled" ou bien les personnes se sont déjà déplacés sur le lieu




Restitution de la voiture





Canceled selon les intervalles de temps

Distribution des Annulations - Canceled - par Intervalle de Temps



Pic d'annulation à 0 min.

1er pic d'annulations dans les 30/60 minutes

2e cluster d'annulations dans les 300/700 minutes



Création d'un moteur de seuil

Quelques données :


- nb de canceled total : **3265**
- % de canceled total : **15,32%**
- nbre de canceled à la 2e location : **194**
- % de canceled 2e location : **12,42%**
- % de canceled 2e location sur total : **0,91%**
- % Canceled 2e local sur total : **5,94%**

N.B : temps delta > 0

Choisissez une fenêtre de temps d'action (en minutes)



Concentration des Annulations en Fonction du Temps



Analyse pour la fenêtre de temps de 206 minutes

Taux d'Annulation Ciblé ⓘ

4.55%

Annulations Mobiles Ciblées

2.18%

Annulations Desktop Ciblées

2.37%

Clients Perdus dans ce délai (nb)

71

Impact sur le total des locations (%)


0.33%

Part du Problème Ciblée (%) ⓘ

63.40%

Si on souhaite rester dans 5% de pertes en 2e location il faut rester en dessous de 200 min.

À une époque du temps réel, les retards sont “psychologiquement” problématiques mais sur l’ensemble des “canceled”, cela représente très peu.



Moteur de prédiction de prix

EDA : get_around_pricing_project.csv

skippy summary

Data Summary		Data Types	
Dataframe	Values	Column Type	Count
Number of rows	4842		
Number of columns	15		
		bool	7
		int64	4
		string	4

number										
column	NA	NA %	mean	sd	p0	p25	p50	p75	p100	hist
Unnamed: 0	0	0	2421	1398	0	1210	2420	3631	4842	
mileage	0	0	141000	60200	-64	103000	141100	175200	1000000	
engine_power	0	0	129	38.95	25	100	120	135	423	
rental_price_per_day	0	0	121.2	33.57	10	104	119	136	422	

bool			
column	true	true rate	hist
private_parking_available	2662	0.55	
has_gps	3839	0.79	
has_air_conditioning	978	0.2	
automatic_car	962	0.2	
has_getaround_connect	2230	0.46	
has_speed_regulator	1169	0.24	
winter_tires	4514	0.93	


string									
column	NA	NA %	shortest	longest	min	max	chars per row	words per row	total words
model_key	0	0	PGO	Lamborghini	Alfa Romeo	Yamaha	6.04	1	4848
fuel	0	0	diesel	hybrid_petrol	diesel	petrol	6.01	1	4842
paint_color	0	0	red	silver	beige	white	4.66	1	4842
car_type	0	0	suv	convertible	convertible	van	5.63	1	4842


End

Note générale :

- pas de valeurs manquantes
- Valeurs aberrantes dans
 - engines
 - mileage

Nettoyage de base : $3 \times \text{STD}$





Les modèles testés

```

✓ LINEAR REGRESSION - RÉSULTATS FINAUX ✓
🔧 Run ID: 55e04ecd3744413db1b5d5b35294a7d5

=====

🔍 HYPERPARAMÈTRES:
• Aucun hyperparamètre à optimiser pour ce modèle.

📊 SCORE R² MOYEN (Validation Croisée): 0.6747

✓ MÉTRIQUES SUR L'ENSEMBLE D'ENTRAÎNEMENT:
• R² Score: 0.6901
• MAE: 11.96
• RMSE: 17.84

🔧 MÉTRIQUES SUR L'ENSEMBLE DE TEST:
• R² Score: 0.7267
• MAE: 12.15
• RMSE: 16.95
    
```



Modèle stable mais
peu performant

```

🔍 RANDOM FOREST REGRESSOR - RÉSULTATS FINAUX 🔍
🔧 Run ID: 5198b078007c4cca81910fa5af22013f

=====

🔍 MEILLEURS HYPERPARAMÈTRES TROUVÉS:
• max_depth: 30
• min_samples_leaf: 1
• min_samples_split: 4
• n_estimators: 200

📊 MEILLEUR SCORE R² (Validation Croisée): 0.7104

✓ MÉTRIQUES SUR L'ENSEMBLE D'ENTRAÎNEMENT:
• R² Score: 0.9426
• MAE: 4.68
• RMSE: 7.68

🔧 MÉTRIQUES SUR L'ENSEMBLE DE TEST:
• R² Score: 0.7948
• MAE: 10.09
• RMSE: 14.69
    
```



Belles métriques mais
overfitting

```

🔍 XGB00ST - RÉSULTATS FINAUX 🔍
🔧 Run ID: 1bb55a0130904a569f0180bcad36a649

=====

🔍 MEILLEURS HYPERPARAMÈTRES TROUVÉS:
• learning_rate: 0.05
• max_depth: 5
• n_estimators: 300

📊 MEILLEUR SCORE R² (Validation Croisée): 0.7266

✓ MÉTRIQUES SUR L'ENSEMBLE D'ENTRAÎNEMENT:
• R² Score: 0.8512
• MAE: 8.20 $
• RMSE: 12.36 $

🔧 MÉTRIQUES SUR L'ENSEMBLE DE TEST:
• R² Score: 0.7924
• MAE: 10.12 $
• RMSE: 14.77 $
    
```




Belle métriques,
bonne généralisation

R2 Score : proportion de la variance des valeurs réelles qui est expliquée par le modèle

MAE (Mean Absolute Error) : erreur moyenne absolue entre les valeurs prédites et réelles

RMSE (Root Mean Squared Error) : racine de l'erreur quadratique moyenne (pénalise les grosses erreurs).



Régulation Ridge Vs Lasso

🚀 XGBOOST avec Régularisation L2 (Ridge) – RÉSULTATS 🚀

🔧 Run ID: 7a25968cdbfa478db77308989de224fa

🔍 MEILLEURS HYPERPARAMÈTRES TROUVÉS:

- learning_rate: 0.1
- max_depth: 5
- n_estimators: 300
- reg_lambda: 1

📊 MEILLEUR SCORE R^2 (Validation Croisée): 0.7419

✅ MÉTRIQUES SUR L'ENSEMBLE D'ENTRAÎNEMENT:

- R^2 Score: 0.8935
- MAE: 7.02 \$
- RMSE: 10.46 \$

🔧 MÉTRIQUES SUR L'ENSEMBLE DE TEST:

- R^2 Score: 0.7928
- MAE: 9.99 \$
- RMSE: 14.76 \$



🚀 XGBOOST avec Régularisation L1 (Lasso) – RÉSULTATS 🚀

🔧 Run ID: b4c5453d597d48fca32d4be6097d450f

🔍 MEILLEURS HYPERPARAMÈTRES TROUVÉS:

- learning_rate: 0.1
- max_depth: 5
- n_estimators: 300
- reg_alpha: 1

📊 MEILLEUR SCORE R^2 (Validation Croisée): 0.7300

✅ MÉTRIQUES SUR L'ENSEMBLE D'ENTRAÎNEMENT:

- R^2 Score: 0.8932
- MAE: 7.06 \$
- RMSE: 10.48 \$

🔧 MÉTRIQUES SUR L'ENSEMBLE DE TEST:

- R^2 Score: 0.7870
- MAE: 10.06 \$
- RMSE: 14.96 \$

Résultats globalement bon, l'**overfitting** est contenu. **Xgboost** avec Ridge bat Lasso d'une très courte de tête.

mlflow Management des résultats ML

mlflow 3.2.0

Experiments

08_GETAROUND Provide Feedback Add Description

Runs Models Experimental Evaluation Traces

metrics.rmse < 1 and params.model = "tree" Time created State: Active Datasets Sort: Created Columns

Expand rows Group by

	Run Name	Created	Dataset	Duration	Source	Models	R2_test	R2_train
	Run_XGBoost_Ridge...	3 days ago	dataset (09efb078) Train , dataset (-	47.9s	ipykern...	sklearn +2	0.7958703...	0.8666484...
	Run_RandomForest...	3 days ago	dataset (26a6f83) Eval , dataset (-	4.4min	ipykern...	sklearn +2	0.794848...	0.9425867...
	Run_XGBoost_Ridge...	3 days ago	dataset (09efb078) Train , dataset (-	43.9s	ipykern...	sklearn +2	0.7958703...	0.8666484...
	Run_XGBoost_Lass...	3 days ago	dataset (26a6f83) Eval , dataset (-	41.7s	ipykern...	sklearn +2	0.7870385...	0.8931801...
	Run_XGBoost_Tofd...	3 days ago	dataset (09efb078) Train , dataset (-	45.9s	ipykern...	sklearn +2	0.7923833...	0.8512345...
	Run_LinearRegressi...	3 days ago	dataset (09efb078) Train , dataset (-	41.9s	ipykern...	sklearn +2	0.7267177...	0.6901303...

Comparaison sous MLFLOW

Code de la prédiction accessible ici directement

mlflow 3.2.0

Experiments

08_GETAROUND

Run_XGBoost_Ridge_20250815_214650

Overview Model metrics System metrics Traces Artifacts

test_estimator

model

xgboost_ridge_pipeline

Path: x3jmlflowc720b6657eb68943298f1124f0db522/artifacts/xgboost_ridge_pipeline

Register model

Make Predictions

Predict on a Pandas DataFrame:

```
import mlflow
logged_model = 'runs:/86657eb68943298f1124f0db522/xgboost_ridge_pipeline'

# Load model as a PyFuncModel.
loaded_model = mlflow.pyfunc.load_model(logged_model)

# Predict on a Pandas DataFrame.
import pandas as pd
loaded_model.predict(pd.DataFrame(data))
```

Predict on a Spark DataFrame:


```
import mlflow
from pyspark.sql.functions import struct, col
logged_model = 'runs:/86657eb68943298f1124f0db522/xgboost_ridge_pipeline'

# Load model as a Spark UDF. Override result_type if the model does not return double values.
loaded_model = mlflow.pyfunc.spark_udf(logged_model)

# Predict on a Spark DataFrame.
df = mlflow.spark.predictions(loaded_model(struct(col, of.columns)))
```



ML OPS GETAROUND





Démo

URL DEMO :

<https://huggingface.co/spaces/ericjedha/getaroundST>

Back Up Vidéo de la démo






Conclusion

Le simulateur de Seuil ne va pas radicalement changer le business de GetAround (moins de 1% des “Annulations” est dû aux retards) mais, la promesse de l’entreprise c’est “**The Car you Want Wen you Want it**”.

Il faut donc régler cette histoire de retard, la **eRéputation** de Getaround en dépend. Quelques idées : des **notifications**, des **frais supplémentaires** pour tout retard de plus de 2h, des bonus pour les personnes sérieuses etc.

Il faut aussi chercher pourquoi il y a des **annulations** quand il n’y a pas de retard.



Merci de
votre attention